

ĐẠI HỌC QUỐC GIA TP.HCM  
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Trần Nguyễn Khải Luân  
Nguyễn Bảo Duy  
Trương Quốc Cường  
Nguyễn Thanh Tiến

# Nghiên cứu về khả năng học chính xác thuật toán của mạng nơ-ron

*Bài báo: Learning to Add, Multiply, and Execute Algorithmic Instructions  
Exactly with Neural Networks*

Môn học: Nhập môn Học máy

TP. Hồ Chí Minh, Năm 2025

ĐẠI HỌC QUỐC GIA TP.HCM  
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Trần Nguyễn Khải Luân  
Nguyễn Bảo Duy  
Trương Quốc Cường  
Nguyễn Thanh Tiến

# Nghiên cứu về khả năng học chính xác thuật toán của mạng nơ-ron

*Bài báo: Learning to Add, Multiply, and Execute Algorithmic Instructions  
Exactly with Neural Networks*

Môn học: Nhập môn Học máy

Giảng viên hướng dẫn: ThS. Lê Nhật Nam

TP. Hồ Chí Minh, Năm 2025

# THÔNG TIN NHÓM

- **Nhóm:** 11
- **Nhóm trưởng:** Trương Quốc Cường - 23127333
- **Danh sách thành viên:**
  1. Trần Nguyễn Khải Luân - 23127006
  2. Nguyễn Bảo Duy - 23127179
  3. Nguyễn Thanh Tiến - 23127539

## Mục lục

|          |                                                                 |          |
|----------|-----------------------------------------------------------------|----------|
| <b>1</b> | <b>TỔNG QUAN</b>                                                | <b>1</b> |
| 1.1      | Giới thiệu . . . . .                                            | 1        |
| 1.2      | Các nghiên cứu liên quan . . . . .                              | 1        |
| 1.3      | Động lực nghiên cứu . . . . .                                   | 2        |
| 1.4      | Câu hỏi nghiên cứu . . . . .                                    | 2        |
| 1.5      | Đóng góp của báo cáo . . . . .                                  | 3        |
| <b>2</b> | <b>CƠ SỞ LÝ THUYẾT</b>                                          | <b>4</b> |
| 2.1      | Ký hiệu và các khái niệm cơ bản . . . . .                       | 4        |
| 2.2      | Neural Tangent Kernel (NTK) . . . . .                           | 4        |
| 2.3      | Giới hạn chiều rộng vô hạn . . . . .                            | 4        |
| 2.4      | Mạng nơ-ron hai lớp . . . . .                                   | 4        |
| 2.5      | Điều kiện về khả năng học chính xác . . . . .                   | 4        |
| <b>3</b> | <b>PHƯƠNG PHÁP ĐỀ XUẤT</b>                                      | <b>5</b> |
| 3.1      | Kỹ thuật Template Matching . . . . .                            | 5        |
| 3.2      | Cấu trúc dữ liệu và Trục giao hóa . . . . .                     | 5        |
| 3.3      | Định lý về bộ dự báo NTK (NTK Predictor Behavior) . . . . .     | 5        |
| 3.4      | Kiểm soát tương quan không mong muốn (Assumption 5.1) . . . . . | 5        |
| 3.5      | Triển khai thuật toán . . . . .                                 | 5        |
| 3.5.1    | Phép hoán vị . . . . .                                          | 5        |
| 3.5.2    | Phép cộng . . . . .                                             | 5        |
| 3.5.3    | Phép nhân . . . . .                                             | 5        |
| 3.5.4    | Tính toán tổng quát với SBN . . . . .                           | 5        |
| 3.6      | Độ phức tạp tập hợp . . . . .                                   | 5        |
| <b>4</b> | <b>THỰC NGHIỆM VÀ PHÂN TÍCH</b>                                 | <b>6</b> |

|          |                                                 |           |
|----------|-------------------------------------------------|-----------|
| 4.1      | Thiết lập thực nghiệm . . . . .                 | 6         |
| 4.2      | Xác minh lý thuyết . . . . .                    | 6         |
| 4.2.1    | Kết quả trên phép cộng và nhân . . . . .        | 6         |
| 4.2.2    | So sánh phương sai và kỳ vọng . . . . .         | 6         |
| 4.3      | Thực nghiệm huấn luyện . . . . .                | 6         |
| 4.3.1    | Bài toán Hoán vị . . . . .                      | 6         |
| 4.3.2    | Độ chính xác theo kích thước Ensemble . . . . . | 6         |
| <b>5</b> | <b>KẾT LUẬN</b>                                 | <b>7</b>  |
| <b>A</b> | <b>Chứng minh toán học bổ trợ</b>               | <b>9</b>  |
| <b>B</b> | <b>Mã nguồn cài đặt mô phỏng</b>                | <b>10</b> |

## Danh sách bảng

## Danh sách hình vẽ

# Chương 1

## TỔNG QUAN

### 1.1 Giới thiệu

Mạng nơ-ron đã chứng minh khả năng xấp xỉ vượt trội đối với các hàm liên tục và trơn, đặc biệt trong các bài toán nhận dạng mẫu, xử lý ngôn ngữ tự nhiên và thị giác máy tính. Tuy nhiên, khi đối mặt với các phép toán rời rạc như phép cộng nhị phân, phép nhân số học hay thực thi các chỉ thị thuật toán, mạng nơ-ron truyền thống thường gặp khó khăn đáng kể. Sự đối lập này phản ánh thách thức cơ bản: trong khi mạng nơ-ron được tối ưu hóa cho việc xấp xỉ hàm số trong không gian liên tục, các thuật toán thực tế yêu cầu sự chính xác tuyệt đối ở cấp độ bit.

Nghiên cứu đã đề xuất một hướng tiếp cận đột phá để giải quyết vấn đề này thông qua khung lý thuyết Neural Tangent Kernel (NTK). Bằng cách phân tích mạng nơ-ron hai lớp trong giới hạn chiều rộng vô hạn, các tác giả chứng minh rằng mạng nơ-ron có thể được huấn luyện để thực thi chính xác các chỉ thị thuật toán được mã hóa ở dạng nhị phân. Đây là kết quả có ý nghĩa lý thuyết quan trọng, mở ra khả năng sử dụng mạng nơ-ron như một công cụ tính toán phổ quát thay vì chỉ giới hạn ở vai trò xấp xỉ hàm số.

Mục tiêu cốt lõi của nghiên cứu là chứng minh một cách chặt chẽ về mặt toán học rằng mạng nơ-ron, khi được huấn luyện thông qua gradient descent với cơ chế template matching, có khả năng học và thực thi chính xác các chỉ thị thuật toán mà không cần xấp xỉ.

### 1.2 Các nghiên cứu liên quan

Khả năng tính toán của mạng nơ-ron đã được nghiên cứu rộng rãi trong nhiều thập kỷ qua. Các nghiên cứu tiên phong về Recurrent Neural Networks (RNN) đã chứng minh rằng RNN có thể mô phỏng máy Turing (Turing-complete) về mặt lý thuyết, nghĩa là chúng có khả năng biểu diễn bất kỳ hàm tính toán được (computable function) nào. Gần đây hơn, kiến trúc Transformer cũng được chứng minh có khả năng biểu diễn tương đương, củng cố thêm quan điểm về tính phổ quát của mạng nơ-ron.

Tuy nhiên, điều quan trọng cần phân biệt là tính khả thi về mặt biểu diễn (expressive power) hoàn toàn khác với khả năng học được (learnability) thông qua gradient descent. Một mạng nơ-ron có thể có khả năng biểu diễn một hàm phức tạp, nhưng điều đó không đảm bảo rằng thuật toán tối ưu hóa như gradient descent có thể tìm được tập tham số phù hợp để thực hiện hàm đó từ dữ liệu huấn luyện hữu hạn. Đây chính là khoảng cách then chốt mà các nghiên cứu trước đó chưa giải quyết triệt để.

Nhiều kiến trúc chuyên biệt đã được đề xuất để thu hẹp khoảng cách này. Neural GPU mở rộng khả năng của mạng tích chập để xử lý các phép toán số học song song. Neural Arithmetic Logic Unit (NALU) được thiết kế đặc biệt để học các phép toán số học như cộng, trừ, nhân và chia. Mặc dù các kiến trúc này đạt được kết quả thực nghiệm tốt trong một số trường hợp, chúng thiếu nền tảng lý thuyết vững chắc về việc tại sao và khi nào quá trình học hội tụ đến giải pháp chính xác.

Nghiên cứu đã cho thấy sự khác biệt cơ bản ở chỗ chứng minh lý thuyết chặt chẽ dựa trên khung NTK, đảm bảo rằng mạng nơ-ron không chỉ có khả năng biểu diễn mà thực sự có thể học được các phép toán chính xác thông qua gradient descent với lượng dữ liệu huấn luyện có thể kiểm soát được.

## 1.3 Động lực nghiên cứu

Một trong những thách thức cốt lõi khi huấn luyện mạng nơ-ron thực hiện các phép toán rời rạc là sự khó khăn trong việc hội tụ gradient descent đối với các hàm không liên tục. Gradient descent hoạt động dựa trên việc tính toán đạo hàm của hàm mất mát theo các tham số mạng, nhưng đối với các hàm bước nhảy hay các phép toán nhị phân, đạo hàm hầu như bằng không hoặc không xác định tại hầu hết các điểm. Điều này dẫn đến hiện tượng gradient biến mất (vanishing gradient) hoặc gradient không cung cấp thông tin hữu ích cho việc cập nhật tham số.

Các bộ dữ liệu tiêu chuẩn cho bài toán số học thường không được thiết kế để giải quyết vấn đề này một cách có hệ thống. Hệ quả là mạng nơ-ron được huấn luyện trên các bộ dữ liệu như vậy có thể đạt độ chính xác cao trên tập huấn luyện nhưng thất bại khi khái quát hóa (generalization) sang các ví dụ mới, đặc biệt khi kích thước đầu vào tăng lên.

Động lực chính của nghiên cứu này xuất phát từ nhu cầu tìm kiếm một cơ chế huấn luyện có thể đảm bảo mạng nơ-ron đạt được độ chính xác tuyệt đối (exact execution) thay vì chỉ xấp xỉ. Thay vì cố gắng xấp xỉ một hàm rời rạc bằng một hàm liên tục, nghiên cứu này đề xuất mã hóa dữ liệu và thuật toán theo cách cho phép mạng nơ-ron nhận dạng và áp dụng các quy tắc cấp độ bit một cách chính xác thông qua cơ chế template matching. Cách tiếp cận này biến bài toán từ xấp xỉ hàm thành bài toán nhận dạng mẫu, nơi mạng nơ-ron có thể phát huy thế mạnh vốn có.

## 1.4 Câu hỏi nghiên cứu

Câu hỏi nghiên cứu trọng tâm mà tác giả đặt ra là:

*Liệu mạng nơ-ron có thể học thực thi chính xác các chỉ thị thuật toán thông qua cơ chế template matching, và nếu có thể, lượng dữ liệu huấn luyện tối thiểu cần thiết là bao nhiêu?*

Câu hỏi này bao hàm nhiều khía cạnh quan trọng:

- **Tính khả thi về mặt học:** Liệu gradient descent có thể hội tụ đến một giải pháp thực hiện chính xác thuật toán hay không?
- **Hiệu quả dữ liệu:** Số lượng ví dụ huấn luyện cần thiết có thể được kiểm soát ở mức nào? Liệu có thể đạt được độ phức tạp mẫu logarithmic thay vì tuyến tính hay đa thức theo kích thước đầu vào?

- **Tính phổ quát:** Kết quả có thể mở rộng cho lớp các chỉ thị thuật toán nào? Liệu có thể đạt được tính Turing-complete không?

## 1.5 Đóng góp của báo cáo

Nghiên cứu của đã mang lại 5 đóng góp chính về mặt lý thuyết và phương pháp luận:

**Thứ nhất**, các tác giả đề xuất phương pháp biểu diễn thuật toán dưới dạng template (Algorithmic Template Representation). Trong phương pháp này, mỗi quy tắc cấp độ bit của thuật toán được mã hóa thành một vector mẫu riêng biệt. Cách tiếp cận này cho phép cô lập các quy tắc logic và tạo ra cấu trúc dữ liệu phù hợp cho việc áp dụng cơ chế template matching, nơi mạng nơ-ron học cách nhận dạng và áp dụng từng quy tắc một cách chính xác.

**Thứ hai**, nghiên cứu cung cấp chứng minh lý thuyết chặt chẽ dựa trên khung Neural Tangent Kernel (NTK) về khả năng học chính xác các phép toán cơ bản. Cụ thể, các tác giả chứng minh rằng mạng nơ-ron hai lớp trong giới hạn infinite-width có thể học chính xác:

- Phép hoán vị (permutation) trên các bit
- Phép cộng nhị phân (binary addition)
- Phép nhân nhị phân (binary multiplication)
- Chỉ thị Subtract and Branch if Negative (SBN)

**Thứ ba**, nghiên cứu chứng minh tính hiệu quả về dữ liệu của phương pháp đề xuất. Thay vì yêu cầu số lượng ví dụ huấn luyện tỷ lệ tuyến tính hoặc đa thức với kích thước đầu vào, phương pháp này chỉ cần số lượng ví dụ ở quy mô logarithmic. Điều này có ý nghĩa thực tiễn quan trọng, cho phép huấn luyện hiệu quả ngay cả với các bài toán có kích thước đầu vào lớn.

**Thứ tư**, nghiên cứu khẳng định tính phổ quát của khung lý thuyết đề xuất. Vì chỉ thị SBN đã được chứng minh là Turing-complete (tức là bất kỳ hàm tính toán được nào cũng có thể được biểu diễn bằng một chuỗi các chỉ thị SBN), việc chứng minh mạng nơ-ron có thể học chính xác SBN đồng nghĩa với việc mạng nơ-ron có thể, về nguyên tắc, học thực thi bất kỳ thuật toán nào có thể được mô tả bằng một chuỗi hữu hạn các chỉ thị.

**Thứ năm**, báo cáo này tổng hợp và trình bày lại các kết quả từ nghiên cứu gốc dưới góc nhìn giáo dục, giúp người đọc tiếp cận các khái niệm phức tạp như NTK, infinite-width limit, và template matching một cách có hệ thống và dễ hiểu hơn.

Các đóng góp này không chỉ có giá trị về mặt lý thuyết thuần túy mà còn mở ra hướng phát triển mới cho việc thiết kế và huấn luyện mạng nơ-ron trong các ứng dụng yêu cầu độ chính xác tuyệt đối, như xác minh phần cứng, mã hóa và giải mã, và các hệ thống nhúng quan trọng.

## Chương 2

# CƠ SỞ LÝ THUYẾT

2.1 Ký hiệu và các khái niệm cơ bản

2.2 Neural Tangent Kernel (NTK)

2.3 Giới hạn chiều rộng vô hạn

2.4 Mạng nơ-ron hai lớp

2.5 Điều kiện về khả năng học chính xác



## Chương 3

# PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Kỹ thuật Template Matching

3.2 Cấu trúc dữ liệu và Trục giao hóa

3.3 Định lý về bộ dự báo NTK (NTK Predictor Behavior)

3.4 Kiểm soát tương quan không mong muốn (Assumption 5.1)

3.5 Triển khai thuật toán

3.5.1 Phép hoán vị

3.5.2 Phép cộng

3.5.3 Phép nhân

3.5.4 Tính toán tổng quát với SBN

3.6 Độ phức tạp tập hợp

## Chương 4

# THỰC NGHIỆM VÀ PHÂN TÍCH

### 4.1 Thiết lập thực nghiệm

### 4.2 Xác minh lý thuyết

#### 4.2.1 Kết quả trên phép cộng và nhân

#### 4.2.2 So sánh phương sai và kỳ vọng

### 4.3 Thực nghiệm huấn luyện

#### 4.3.1 Bài toán Hoán vị

#### 4.3.2 Độ chính xác theo kích thước Ensemble

## Chương 5

# KẾT LUẬN

# Tài liệu tham khảo

- [1] Artur Back de Luca, George Giapitzakis, and Kimon Fountoulakis, "Learning to Add, Multiply, and Execute Algorithmic Instructions Exactly with Neural Networks", arXiv:2502.16763, 2025.

## Phụ lục A

### Chứng minh toán học bổ trợ

## Phụ lục B

### Mã nguồn cài đặt mô phỏng